

面向智能语音处理的音乐生成与授权歌声音色转换系统

A Music Generation and Authorized Singing-Voice Timbre Conversion System for Intelligent Speech Processing

EDM-Adapter 项目组

摘要

面向音乐生成、歌声音色替换和网页化实验复现的综合需求，本文提出并实现一种双路径智能音频处理系统。系统将文本到音乐生成与授权歌声音色转换拆分为两个独立研究变量：音乐生成路径以 ACE-Step 为基础模型，通过 LoRA 对目标 EDM 数据域进行参数高效适配；音色转换路径以 Demucs 完成人声与伴奏分离，以 Seed-VC 完成零样本歌声音色转换，并在转换后执行去沙哑、能量包络保持、轻混响和伴奏重混。为避免仅凭单个听感样例给出结论，本文建立实验级证据链：每次实验保存输入音频、分轨结果、转换人声、伴奏重混、参数记录、波形频谱诊断图和完整 Mel 水印图。音乐生成实验使用 6016 条 8 秒 EDM 片段，训练/验证/测试划分为 4833/557/626；段落级增强实验进一步构建 360 条 15 秒片段，覆盖 drop=130, breakdown=86, build-up=65, intro=36, loop=25, outro=18 等结构标签。授权音色转换实验以匿名样例 E-VC-01 验证端到端链路，输出时长 279.7 秒，BPM=136.0，RMS=0.1363，低频比例=0.3401，Seed-VC 运行代价 RTF=19.30。实验结果表明，该系统能够把风格适配、歌声音色迁移、分轨重混和 AI 生成标识组织为可复核的智能语音处理流程。项目源代码仓库地址：<https://github.com/anmoryli/edm-adapter>。

关键词：智能语音处理；音乐生成；歌声音色转换；ACE-Step；LoRA；Demucs；Seed-VC；分轨重混；可复现实验

Abstract

This paper presents a dual-path intelligent audio-processing system for controllable music generation and authorized singing-voice timbre conversion. The generation path adapts ACE-Step to an EDM domain through LoRA fine-tuning, while the conversion path combines Demucs source separation, Seed-VC timbre conversion, artifact suppression, dynamics preservation, light vocal reverb, and accompaniment remixing. The system records experiment-level evidence including separated stems, converted vocals, remix outputs, parameter records, waveform diagnostics, and full Mel-spectrogram watermark figures. Experiments show that the proposed prototype can separate style adaptation from vocal timbre transfer and provide reproducible evidence for intelligent speech-processing analysis. Source code repository: <https://github.com/anmoryli/edm-adapter>.

1 引言


智能语音处理的研究对象正在从传统语音识别、语音增强和文本到语音合成扩展到音乐生成、歌声转换、多轨分离和跨媒体音频编辑。这类任务不再只关心语音是否可懂，还需要同时处理旋律、节奏、基频轨迹、音色身份、混音空间和生成结果的可追溯性。在实际网页系统中，用户往往希望上传一首歌后保留旋律与歌词时序，只改变歌手音色；同时也希望模型能够学习某类电子音乐制作风格，并与基础模型输出进行同 seed 对照。如果把这些能力混在一个黑箱按钮里，最终差异可能来自采样 seed、LoRA 权重、分轨误差、F0 估计、声码器伪影或后处理参数，结论将无法复核。

本文围绕 EDM-Adapter 原型系统重新组织研究问题。第一，如何在有限训练资源条件下对大规模音乐生成模型进行参数高效风格适配；第二，如何把上传歌曲中的人声内容和基频轨迹与授权目

标音色样本结合，生成新的目标声线；第三，如何让每一次实验都留下足够的中间产物和图表证据，使实验结果可以被复核、比较和定位问题。因此，本文的目标不是宣称重新训练一个完整基础模型，而是给出一个边界清晰、流程可运行、证据可追踪的智能音频处理框架。

本文主要贡献包括：1）设计音乐生成与授权歌声音色转换的双路径系统架构，避免 LoRA 风格适配与 Seed-VC 音色迁移相互混淆；2）给出歌声音色转换的形式化定义和工程实现链路，包括 Demucs 分轨、Seed-VC 转换、去沙哑、包络保持、轻混响和伴奏重混；3）建立实验级证据链，将输入音频、分轨、转换、重混、参数和诊断图组织为最小复现实验单元；4）在最终生成音频的完整 Mel 图谱末尾加入由频谱能量构成的“AI 生成”负形水印，用于标识 AI 生成结果。

智能语音处理系统总体框架



说明：系统把“音乐生成”和“歌声音色转换”拆成两个实验变量，避免把风格适配、音色迁移和随机采样混在同一结论中。

图 1 系统总体架构。系统将文本到音乐生成、授权歌声音色转换和实验级证据记录组织为三个相互独立但可追踪的模块。

2 相关工作与问题定义

潜变量扩散模型已经成为图像、音频与音乐生成中的重要技术路线。其核心思想是在压缩潜空间中执行逐步去噪，使生成过程可以在较低计算成本下建模长时序信号。ACE-Step 将文本条件、歌词条件、音乐语义表征和压缩声学潜变量结合起来，为长时音乐生成提供基础模型能力。LoRA 则通过冻结预训练权重并学习低秩增量，使大模型适配不再需要更新全部参数，从而降低显存占用、训练时间和实验变量数量。

歌声音色转换与普通 TTS 不同。TTS 的输入通常是文本和说话人条件，目标是从零合成一段朗读语音；歌声音色转换的输入是已经存在的源人声或源歌曲，要求保留歌词时序、咬字节奏、旋律走向和情绪力度，同时改变声学音色身份。因此，转换链路必须显式处理人声与伴奏的耦合关系：伴奏不应被送入声线转换模型，转换后人声也需要重新与伴奏在响度、动态和空间感上融合。


表 1 三类音频任务的边界

任务	输入条件	核心约束
文本到语音 TTS	文本、说话人或音色条件	生成朗读语音，不要求匹配某首歌的旋律和节拍

任务	输入条件	核心约束
文本到音乐生成	prompt、歌词、seed、可选 LoRA	生成新的音乐结构，重点是风格、段落、混音和可控随机性
歌声音色转换	源人声、F0、目标音色样本	保持歌词时序和旋律走向，只替换声学音色并重混伴奏

本文将授权歌声音色转换定义为条件波形重建问题。给定源歌曲、目标音色参考样本和可选半音偏移量，系统从源人声中估计歌唱内容表征与基频轨迹，从参考样本中提取音色嵌入，再由转换模型和声码器生成目标音色人声。该定义把内容保持、音高稳定、音色相似和波形音质四个评价维度分开，使后续误差分析能够定位到具体模块。

音色转换的问题定义与智能语音处理要素



形式化表达见式(1)。评价时同时考察内容保持、音色相似度、音高稳定性和声码器音质。

图 2 授权歌声音色转换的问题定义。源歌曲提供歌唱内容与基频轨迹，目标参考样本提供音色嵌入，转换模型与声码器负责生成目标声线。

$$y_{vc} = \text{Vocoder}(\text{SeedVC}(C(x), F_0(x) + \Delta p, e(r)))$$

表 2 符号定义		
符号	含义	在系统中的来源
x	源歌曲或源人声音频	用户上传音频或 Demucs 分离后的 vocals
$C(x)$	歌词内容、音素时序和歌唱内容表征	Seed-VC 内容编码器
基频轨迹	源人声基频随时间变化的曲线	转换器内部基频/音高条件
$e(r)$	授权目标音色嵌入	目标参考样本或目标音色样本库
y (下标 vc)	转换后人声	Seed-VC 与声码器输出，经后处理修正
a	分离伴奏	drums、bass、other 三轨重混

3 方法

本文方法采用“生成适配”和“声线迁移”分离建模的策略。音乐生成侧只处理从文本条件到音乐结构的分布适配，歌声音色转换侧只处理已有歌唱内容在目标音色条件下的波形重建。这样做可以把风格、旋律、音色、分轨误差和后处理音质分别归因，避免用单个输出样例同时解释多个模型因素。

表 3 技术方案分层		
层次	关键处理	评价关注点
输入与标准化	统一采样率、声道、时长和响度范围，记录实验参数	输入是否可复现，响度是否异常
声源分离	用 Demucs 得到人声、鼓、贝斯和其他声部	人声泄漏、伴奏残留和分轨能量平衡
内容与基频建模	从源人声提取歌唱内容表征和基频轨迹	歌词时序、旋律走向和转调稳定性
音色条件建模	从授权参考样本提取目标音色嵌入	参考样本质量、情绪匹配和授权来源
声线转换与声码器	由 Seed-VC 与声码器生成目标音色人声	音色相似度、咬字清晰度和高频伪影
后处理与重混	去沙哑、包络保持、轻混响、人声增益和伴奏重混	自然度、空间融合和最终混音平衡
证据与水印	输出波形、频谱、完整 Mel 图谱和频谱负形水印	结果可复核性和 AI 生成标识可见性

3.1 音乐生成与 LoRA 适配

音乐生成路径以 ACE-Step 为基础模型，训练数据包含 6016 条 8 秒 EDM 片段，划分为训练/验证/测试=4833/557/626。系统从已有 LoRA 适配器的第 960 步继续训练 240 步，到第 1200 步；可训练范围覆盖最后 2 个 Transformer block，参数量约 1.12M。这种设置保留 MusicDCAE、

文本编码器和大部分扩散主干的通用能力，只让末端去噪决策层学习目标 EDM 数据域的节奏、低频、合成器音色和混音偏移。

$$W' = W + \Delta W, \Delta W = \alpha / r \cdot B \cdot A$$

LoRA 实验采用同种子控制变量设计。实验固定 prompt、歌词、seed、scheduler、采样步数、guidance 和后处理参数，只改变是否加载 LoRA adapter 或 LoRA 权重强度。这样，baseline 与 LoRA 输出从相同随机初态出发，差异主要来自 adapter 对去噪轨迹的影响，而不是来自不同 seed 造成的偶然旋律、鼓组或和声变化。




图 3 LoRA 音乐生成路径。LoRA 只更新少量末端参数，输出通过同 seed baseline 进行控制变量对照。

表 4 LoRA 音乐生成路径的训练与推理步骤


步骤	处理内容	目的
数据标准化	裁剪或补齐 8 秒 EDM 片段，记录 prompt、BPM 和声学特征	降低训练输入分布漂移
潜变量缓存	通过 MusicDCAE 缓存 latent 与文本 token	减少重复编码开销，保证训练可复现
LoRA 续训	冻结基础模型，仅更新末端 LoRA 参数	学习目标数据域的局部生成偏移
同 seed 对照	base 与 LoRA 使用相同 seed、prompt 和采样参数	排除随机初态差异
客观诊断	统计 RMS、低频比例、onset 密度和 Mel 图谱	辅助判断生成差异是否来自风格适配

3.2 授权歌声音色转换链路

歌声音色转换链路包含输入登记、音频标准化、声源分离、转换输入清理、Seed-VC 推理、人声后处理和伴奏重混。系统优先使用 Demucs 将上传歌曲分解为人声、鼓、贝斯和其他声部；若人

声分轨存在，则只将人声送入 Seed-VC，避免伴奏被错误转换。非人声分轨被合成为伴奏，并在最后与转换后人声重新混合，得到完整新歌。

授权音色转换与新歌重混流水线



关键约束：只转换 vocals stem；drums、bass、other 合成为伴奏后参与重混。若分轨失败，系统记录告警并退回整曲转换。

图 4 授权音色转换与新歌重混流水线。系统先分离人声与伴奏，再完成音色替换、人声修复和重混输出。

$$y_{mix} = \text{Normalize}(y_{vc} + g_v \cdot a)$$

式中人声重混增益用于控制转换后人声进入最终混音时的响度比例。转换后人声并不直接与伴奏相加，而是先经过高频去沙哑、能量包络匹配、峰值约束和轻混响。去沙哑用于抑制分轨泄漏和声码器高频毛刺；包络匹配用于保留源人声的演唱力度和情绪起伏；轻混响用于减弱干声贴耳感，使转换后人声更自然地融入伴奏。

表 5 音色转换模块接口

阶段	输入	输出与作用
输入登记	上传歌曲、目标音色参考、转调量、扩散步数、CFG	生成实验参数记录
声源分离	标准化后的歌曲	人声、鼓、贝斯、其他声部
预处理	分离后人声	抑制部分分轨高频噪声，得到转换输入
音色转换	清理后人声、目标音色参考	Seed-VC 输出的初始转换人声
后处理	初始转换人声、源人声能量包络	去沙哑、力度保持、轻混响后的目标音色人声
重混	目标音色人声、伴奏、人声重混增益	完整新歌和 Mel 证据图

3.3 证据链与 AI 水印

为了使实验不依赖口头描述，系统将关键中间产物组织为统一的实验记录单元，包括输入音频副本、分离音轨、转换前后人声、重混输出、参数表、运行记录和声学诊断图。报告中的图表均由这些实验产物重新生成，避免出现无法追溯的数据来源。

针对 AI 生成结果标识，系统在最终音频的完整 Mel 图谱末尾追加一段频谱负形水印区域。该水印不是普通图片文字叠加，而是在 Mel 能量矩阵中构造低能量笔画和高能量边缘，使审阅者打开完整谱图时可以看到“AI 生成”标记，同时保留整首歌原有频谱主体和水印区的时间连续性。

实验记录单元中的可复现实验证据

1	输入副本	源歌曲音频
2	分离人声	vocals stem
3	分离伴奏	伴奏 stem
4	转换人声	目标音色人声
5	重混新歌	完整歌曲输出
6	参数与日志	参数表 / 运行记录 / 指标
7	诊断图	波形 / 频谱 / Mel 水印

说明：每个实验记录单元保存输入、分轨、转换、重混、参数和诊断图，便于复核与复现实验。

图 5 实验记录单元中的可复现实验证据。输入、分轨、转换、重混、参数和诊断图被组织为同一复核链路。

4 实验设置

实验分为三组。第一组验证 LoRA 音乐生成路径是否在同 seed 条件下改变目标风格倾向；第二组验证授权音色转换链路是否能完成分轨、转换、后处理和伴奏重混；第三组验证 AI Mel 水印是否能在完整谱图末尾以频谱形态显现。三组实验共享实验级记录机制，但评价对象不同，因此不混合成一个总评分。

表 6 实验变量与控制条件

实验对象	固定条件	变化或观察项
LoRA 音乐生成	prompt、seed、采样步数、guidance、后处理链路	是否加载 LoRA、LoRA 权重、输出声学指标
歌声音色转换	源歌曲、目标音色目录、分轨策略	pitch shift、steps、CFG、去沙哑、情感保持、人声增益
后处理质量	Seed-VC raw 输出和伴奏	dry/reverb 人声、包络保持、重混响度
Mel 水印	最终输出 wav、采样率、Mel 参数	末尾水印时长、负形字样、完整谱图可读性


表 7 客观指标与解释

指标	计算对象	用途
BPM	最终重混音频	检查节奏估计是否保持在合理范围
RMS	stem 与 mix 波形	比较人声、伴奏和最终输出的能量平衡

指标	计算对象	用途
低频比例	0-250 Hz 能量占比	检查 EDM 低频强度和伴奏泄漏
谱质心	短时频谱	辅助判断明亮度和高频伪影
起音密度	onset 事件数/秒	分析瞬态和节奏稠密度
RTF	推理耗时/音频时长	评估长音频离线处理成本


评价协议强调控制变量。LoRA 实验只改变 adapter 相关变量；音色转换实验只改变目标音色、转调和转换参数；音质修复实验只比较 Seed-VC raw 与后处理输出。若输出出现沙哑、跑调或节奏错位，系统优先回查分轨、F0、声码器和后处理，而不是把问题笼统归因于模型效果不好。

实验变量控制设计



控制变量目的：把“风格适配”“音色迁移”“后处理音质”拆开，避免用一次听感同时解释多个模型因素。

图 6 实验变量控制矩阵。系统将 LoRA 风格适配、歌声音色转换和后处理质量修复拆成独立评价对象。



注：“强”表示主要证据，“辅”表示辅助证据；人工听评用于确认情感、自然度和目标音色相似性。

图 7 客观指标与主观听评的评价矩阵。不同模块对应不同主证据，避免单一指标误导结论。

5 实验结果与分析

5.1 授权音色转换链路验证

在授权音色转换实验 E-VC-01 中，系统保存了从输入音频到最终重混结果的完整证据链。输出音频时长为 279.7 秒，采样率为 44100 Hz，BPM=136.0，RMS=0.1363，低频比例=0.3401，起音密度=2.71/s。这些指标不直接等价于主观音质，但可以用于判断分轨、重混和高频伪影是否出现明显异常。




图 8 分离音轨与重混证据。左侧比较各分轨和最终输出能量，右侧列出实验级产物，说明结果来自可复核链路。




图 9 音色转换输出的波形、频谱与客观指标。该图用于检查响度、频带分布和短时异常。

表 8 授权音色转换实验记录

项目	记录	解释
实验编号	E-VC-01	作为论文中的匿名复现实验单元
输出属性	完整重混歌曲	279.7s / 44100Hz
分轨状态	已分离人声、鼓、贝斯和其他伴奏，并由非人声分轨合成伴奏	判断是否满足“人声转换+伴奏重混”的实验前提
客观指标	BPM=136.0, RMS=0.1363	低频比例=0.3401, onset=2.71/s
运行代价	Seed-VC 离线推理	RTF=19.30

从结果链路看，分离音轨和重混输出同时存在，说明系统不是只返回转换后人声，而是能够将目标音色人声与伴奏组合为新的完整歌曲。若后续听感仍出现沙哑，应重点比较初始转换人声与加入轻混响后人声的频谱差异；若情绪力度不足，应比较源人声能量包络与后处理后目标音色人声包络，而不是仅调整重混音量。

5.2 LoRA 生成路径与段落级数据增强

LoRA 生成路径的实验目标不是证明某一首输出主观上更像目标艺术家，而是建立可复现的目标域适配证据。同 seed baseline 对照用于排除随机初态影响；15 秒段落级数据集用于增强 intro、breakdown、build-up、drop 等结构片段的学习信号。当前段落级数据集包含 360 条样本、142 个来源，结构分布为 drop=130, breakdown=86, build-up=65, intro=36, loop=25, outro=18。

表 9 秒段落级 LoRA 二次微调方案

环节	实施方式	预期作用
片段构建	按 intro、breakdown、build-up、drop 等结构切片	让训练目标从整曲平均风格转向段落结构
样本均衡	保留各结构标签计数和划分文件	避免模型只学习高频出现的 drop 片段
继续训练	从已有 LoRA bundle 初始化，更新末端 block、conditioning 与 final layer	保留已有风格适配，同时加强 15 秒结构生成
同种子评估	baseline、旧 LoRA、新 LoRA 三方对比	判断提升来自二次微调而不是随机种子差异
水印输出	生成完整 Mel 图谱并在末尾加入频谱水印	让 AI 生成标识成为最终证据链的一部分




图 10 同 seed LoRA 与 baseline 的客观音频诊断。该图作为音乐生成路径的基线证据，与音色转换路径分开解释。





图 11 段落级 LoRA 二次微调与 AI 水印 Mel 证据。右侧完整 Mel 图谱末尾显示由频谱能量构成的“AI 生成”负形水印。

5.3 后处理、运行代价与误差来源

针对长音频任务，系统记录了输入时长约 279.7 秒、扩散步数 50、CFG=0.75、去沙哑强度 0.75、情感保持 1.00 和预计耗时约 381.8 分钟。整曲转换更适合作为离线实验执行，交互式系统适合先用短片段筛选转调量、CFG、扩散步数和后处理参数。


后处理链路被拆成三个可解释步骤。第一，高频抑制与谱平滑减少声码器毛刺和分轨泄漏；第二，包络匹配把源 vocals 的能量起伏传递到转换后人声，避免声线被压平；第三，轻混响在转换人声和伴奏之间提供空间过渡，但混响量过大也会降低咬字清晰度。

去沙哑与情感力度保留后处理链路



情感/力度保留系数：1.00。该系数越高，转换后包络越接近原人声，但也可能保留源歌手局部瑕疵。

图 12 去沙哑、情感力度保持与轻混响后处理链路。该链路用于抑制高频毛刺、保留演唱力度并改善人声融入伴奏的自然度。



整曲时长约 279.7s；任务记录估算约 381.8 分钟。实验采用短片段筛参、整曲离线复核的资源管理策略。

图 13 Seed-VC 长音频推理资源预算。图中区分短片段实测、整曲估计和离线任务策略。

音色转换结果异常的错误来源分析




图 14 音色转换异常来源分析。沙哑、跑调、耗时和音色不稳定分别映射到分轨、F0、声码器、参考样本和资源预算等可检查环节。

6 讨论

本文系统的优点是模块边界明确、证据链完整，并且能把听感问题映射到具体技术环节。如果输出声音沙哑，应先检查分轨泄漏和声码器高频伪影，再调节去沙哑强度；如果情感不足，应检查源人声包络和情感保持系数；如果整曲任务耗时过长，应采用短片段参数筛选和整曲离线处理，而不是把耗时问题写成模型失败。

局限性也需要明确。第一，当前音色相似性仍缺少大规模主观听评和统计显著性检验；第二，Seed-VC 在长歌曲上的推理代价较高，适合离线复核而不是频繁交互式试错；第三，目标音色样本的授权、质量和情绪匹配会显著影响最终结果；第四，LoRA 音乐生成路径与歌声音色转换路径虽然在系统中并列呈现，但二者评价指标不同，不能用同一个分数概括。

表 10 局限性与后续改进

问题	当前处理	后续工作
音色相似性量化不足	保留任务证据和客观声学指标	增加目标音色相似度模型和人工听评
长音频推理较慢	短片段筛参、整曲离线复核	加入缓存、分段拼接和 GPU 推理部署
分轨泄漏影响转换	保存 stems 并记录警告	加入 vocals 能量阈值和分轨质量评分
授权与伦理约束	以用户提供目标样本为条件	加入授权确认、来源记录和水印检测流程

7 结论

本文提出并实现了一个面向智能语音处理的音乐生成与授权歌声音色转换系统。系统在音乐生成侧使用 ACE-Step 与 LoRA 完成目标 EDM 数据域适配，在歌声音色转换侧使用 Demucs 和

Seed-VC 完成人声分离、音色迁移和伴奏重混。与单纯展示生成样例不同，本文强调实验级复现实验单元，保存输入、分轨、转换、后处理、重混、参数、指标和 Mel 水印图。实验表明，该系统能够把音乐风格适配、授权音色转换和 AI 生成标识组织为一条可检查的工程链路，为后续加入主观听评、音色相似度度量和高性能推理部署提供基础。

参考资料

- [1] Ho J, Jain A, Abbeel P. Denoising Diffusion Probabilistic Models[C]//Advances in Neural Information Processing Systems. 2020.
- [2] Rombach R, Blattmann A, Lorenz D, Esser P, Ommer B. High-Resolution Image Synthesis with Latent Diffusion Models[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022.
- [3] Copet J, Kreuk F, Gat I, et al. Simple and Controllable Music Generation[C]//Advances in Neural Information Processing Systems. 2023.
- [4] Gong J, Zhao W, Wang S, Xu S, Guo J. ACE-Step: A Step Towards Music Generation Foundation Model[J/OL]. arXiv:2506.00045, 2025.
- [5] Hu E J, Shen Y, Wallis P, et al. LoRA: Low-Rank Adaptation of Large Language Models[C]//International Conference on Learning Representations. 2022.
- [6] Défossez A, Synnaeve G, Adi Y. Hybrid Spectrogram and Waveform Source Separation[C]//ISMIR Workshop, 2021.
- [7] Plachtaa. Seed-VC: zero-shot singing voice conversion toolkit[EB/OL]. GitHub repository.
- [8] Lee S, Ping W, Ginsburg B, Catanzaro B, Yoon S. BigVGAN: A Universal Neural Vocoder with Large-Scale Training[C]//International Conference on Learning Representations. 2023.
- [9] McFee B, Raffel C, Liang D, et al. librosa: Audio and Music Signal Analysis in Python[C]//Proceedings of the 14th Python in Science Conference. 2015.
- [10] Kilgour K, Zuluaga M, Roblek D, Sharifi M. Fréchet Audio Distance: A Reference-Free Metric for Evaluating Music Enhancement Algorithms[C]//Interspeech. 2019.